

Social Network Analysis

Special Lecture 1: Project Proposal Review & Experimental Design

Dr. Hung-Nghiep Tran
nghiepth@uit.edu.vn


University of Information Technology, VNU-HCM, Vietnam
2026

Nội dung chính

- End-to-end Machine Learning pipeline
- Project proposal: tiêu chí đánh giá
- Experimental design & Experimental plan

End-to-End ML Pipeline

Foundations: The Scientific Method



Vì sao ML pipeline quan trọng?

Trong nghiên cứu và ứng dụng AI:

- Mô hình chỉ là một phần nhỏ
- Phần lớn vấn đề nằm ở:
 - đặt bài toán
 - dữ liệu
 - cách đánh giá
 - thiết kế thí nghiệm

Một pipeline kém có thể làm:

- mô hình tốt nhưng kết quả không cao
- kết quả cao nhưng không đáng tin

End-to-End ML Pipeline (tổng quan)

Một ML pipeline cơ bản gồm:

- 1. Problem Formulation**
 - a. Task definition, assumptions, constraints
 - b. Metric definition & evaluation protocol
- 2. Data Pipeline**
 - a. Data collection & understanding
 - b. Train / validation / test split & leakage prevention
 - c. Preprocessing & feature engineering
- 3. Modeling & Training**
 - a. Model selection, baseline & proposed method
 - b. Training, continuous validation, tuning
 - c. Reproducibility details
- 4. Evaluation & Analysis**
 - a. Final evaluation & comparison
 - b. Ablation analysis, error analysis
- 5. Presentation & Reporting**
- 6. Deployment, Serving & Monitoring**

→ Đây là 1 quy trình lặp, mỗi bước đều có thể nhảy về các bước trên.

→ Người làm nghiên cứu phải hiểu rõ và kiểm soát được mỗi bước.

Vài nguyên lý Best Practices của ML pipeline

- **Backward design:** business goal → evaluation metrics → modeling & training...
- **Iterative workflow:** simple baseline → modification & evaluation → repeat & improve
- **Get your hands dirty:** learn by (re)implementing, training, evaluating the model

Martin Zinkevich, "Rules of Machine Learning: Best Practices for ML Engineering," Google
Andrew Ng, "Machine Learning Course," Stanford

Problem formulation

Câu hỏi đầu tiên không phải là: *dùng model gì?*

Mà là:

- Bài toán thực tế là gì, output mục tiêu, các ràng buộc?
- Chuyển về bài toán hình thức nào, vd classification hay regression?
- Có các dòng dữ liệu nào, đại diện cho cái gì?
- Thành công trong thực tế được đo bằng KPIs nào, metrics nào?
- Trong quá trình phát triển thì dùng các metrics mô phỏng nào?

Sai ngay từ bước này → mọi thứ phía sau đều sai.

Data splitting và data leakage

Nguyên tắc cơ bản:

- Tách train / validation / test càng sớm càng tốt
- Không dùng thông tin từ validation/test để:
 - fit scaler
 - chọn feature
 - điều chỉnh pipeline

Ví dụ leakage phổ biến:

- Chuẩn hóa dữ liệu trước khi split
- Dữ liệu có yếu tố thời gian nhưng split ngẫu nhiên

Baseline là gì?

Baseline là:

- phương pháp đơn giản
- dễ tái tạo
- đại diện cho cách làm phổ biến

Baseline tốt giúp trả lời:

Nếu không làm gì phức tạp, kết quả sẽ ra sao?

Ví dụ:

- Dummy baseline: e.g., default / random / most frequent
- Simple baseline: e.g., linear / logistic regression, simple tree-based model
- Recent state-of-the-art baseline

Proposed method là gì?

Proposed method không nhất thiết là model mới.

Có thể là:

- đặc trưng mới
- nguồn dữ liệu mới
- cách kết hợp nhiều mô hình
- pipeline mới

Điều quan trọng:

- phải có lý do
- phải so sánh được với baseline

Baseline vs Proposed Method

(tư duy nghiên cứu)

Một kết quả nghiên cứu hợp lệ cần trả lời:

- So với baseline nào?
- Proposed method cải thiện baseline ở đâu?
- Mức cải thiện có ý nghĩa thực sự không?

Nếu không trả lời được 3 câu này:

- rất khó viết paper
- luận văn dễ bị đánh giá yếu

Ablation study là gì?

Ablation study dùng để trả lời:

Thành phần nào thực sự tạo ra cải thiện?

Cách làm phổ biến là thí nghiệm so sánh:

- Proposed method (full)
- Proposed method bỏ thành phần A
- Proposed method bỏ thành phần B
- ...

→ So sánh các kết quả để chứng minh thành phần nào đóng góp nhiều.

Ví dụ ablation study

Ví dụ proposed method gồm nhiều thành phần:

- tabular features
- text embedding
- graph features

Ablation:

- bỏ tabular features
- bỏ text embedding
- bỏ graph features

Nếu bỏ thành phần nào làm performance giảm rõ rệt:
→ thành phần đó có giá trị.

Reproducibility là yêu cầu bắt buộc

Một thí nghiệm tốt phải:

- chạy lại được
- cho kết quả tương tự

Yêu cầu tối thiểu:

- cố định random seed
- ghi rõ phiên bản thư viện
- lưu cấu hình thí nghiệm
- lưu kết quả ra file

Không reproducible → không đáng tin.

Đánh giá mô hình đúng cách

Sử dụng metrics đúng bài toán:

- Regression:
 - MAE, RMSE (ưu tiên hơn R^2)
 - ...
- Classification:
 - Accuracy phổ biến nhưng không đủ (nếu mất cân bằng lớp)
 - Precision, Recall, F1, ROC-AUC, PR-AUC
 - ...

Metric cần phải:

- phù hợp bài toán
- giải thích được về mặt nghiệp vụ

Error analysis

Không chỉ nhìn con số.

Cần hỏi:

- mô hình sai nhiều ở nhóm dữ liệu nào?
- lỗi có pattern gì?
- có gợi ý feature hoặc mô hình mới không?

Error analysis là nguồn ý tưởng cho:

- proposed method
- hướng nghiên cứu tiếp theo

Project Proposal

Proposal tốt vs proposal yếu

Proposal yếu thường:

- mô tả mơ hồ
- nói nhiều về công nghệ
- chưa rõ dữ liệu
- chưa rõ so sánh với ai

Proposal tốt:

- câu hỏi rõ ràng
- dữ liệu cụ thể
- baseline rõ ràng
- biết mình đang chứng minh điều gì

Proposal không phải là cam kết, mà là giả thuyết

Proposal = giả thuyết ban đầu

- Có thể sai
- Có thể phải điều chỉnh
- Nhưng phải **có thể kiểm chứng**

Một proposal tốt cho phép:

- thiết kế experiment
- phản biện
- cải tiến theo kết quả

Tiêu chí review proposal

Mỗi proposal sẽ được đánh giá theo:

1. Problem formulation
2. Dataset & feasibility
3. Baseline
4. Proposed idea
5. Evaluation plan & goals

Mục tiêu:

- không chấm điểm
- mà để tìm rủi ro và hướng cải thiện

Rubric review chi tiết

1. Problem

- Bài toán có rõ ràng không?
- Có phải bài toán ML/AI thật không, hay chỉ là demo?
- Có các tài liệu liên quan nào, nó ảnh hưởng gì đến bài toán?

2. Data

- Có nguồn dữ liệu nào; có đủ lớn, đủ sạch, đủ nhãn không?
- Có tính thực tế thế nào, có lợi thế nào, có rủi ro gì?

3. Baseline

- Baseline là gì; có đủ mạnh để so sánh không?

4. Proposed Idea

- Proposed cải thiện ở điểm nào? Nếu không cải thiện, có kế hoạch B không?

5. Evaluation

- Sử dụng metrics nào? Kết quả metrics tốt có nghĩa gì trong thực tế?
- Các research questions / hypotheses nào; các mục tiêu dự kiến nào?

Review session: protocol

Mỗi nhóm:

- 5 phút trình bày proposal
- 5 phút phản biện

→ Trình bày tập trung vào outline chính và câu hỏi rubric

→ Chưa cần demo / code / experiment cụ thể

Tham gia vào phản biện

Mỗi học viên nên chú ý lắng nghe và có thể tham gia phản biện proposal nhóm khác.

Tham gia vào phản biện giúp:

- nhóm được hỏi tốt hơn
- người hỏi hiểu sâu hơn

Một số dạng câu hỏi:

- Câu hỏi về bài toán, theo kinh nghiệm chuyên môn của người hỏi
- Câu hỏi về dữ liệu / baseline / proposed idea, dưới góc nhìn của người hỏi
- Câu hỏi về metrics / expected results / ý nghĩa của kết quả thực tế
- ...

Experimental Design

Từ proposal đến experimental design

Câu hỏi quan trọng:

Proposal này sẽ được kiểm chứng bằng các thí nghiệm nào?

Experimental design trả lời:

- chạy mô hình nào?
- so sánh với ai?
- đo bằng gì?
- bao nhiêu lần?
- trong điều kiện nào?

Experimental design là gì?

Experimental design là việc xây dựng 1 **experimental plan** một cách **có chiến lược**

Experimental design cần lưu ý:

- câu hỏi / giả thuyết nào đang được kiểm tra?
- tập dữ liệu nào có thể sử dụng hoặc cần xây dựng?
- biến nào là độc lập? biến nào là phụ thuộc? yếu tố nào cần kiểm soát?

Trong ML/AI, cần lưu ý thêm:

- data split
- model choice
- hyperparameters
- metric

Một experimental plan tối thiểu cần gì?

Một experimental plan tối thiểu gồm:

- Dataset (phiên bản cụ thể)
- Train/val/test strategy
- Baseline models
- Proposed models
- Metrics
- Ablation studies

→ sẵn sàng chạy thí nghiệm.

Ví dụ experimental plan (đơn giản)

Ví dụ:

- Dataset: Customer churn (N=20,000), url, licence
- Split: 70/15/15, stratified
- Baseline: Logistic regression, Random forest
- Proposed: XGBoost + text embedding features
- Metric: F1, ROC-AUC
- Ablation:
 - without text features
 - without feature scaling
- ...

Những lỗi experimental design phổ biến

- Rò rỉ dữ liệu
- So sánh không công bằng
- Chỉ chạy một random seed
- Tuning nhiều thứ cùng lúc
- Không có ablation analysis
- Chọn metric không phù hợp

→ kết quả không đáng tin

→ khó publish

→ khó bảo vệ

Thank you for listening

Q & A